

Gestión del Conocimiento en las Organizaciones

Content-based-filtering-model

Alberto Oria Martín
(alu0101415598@ull.edu.es)

Izan Pérez González
(alu0101543345@ull.edu.es)

Airam Prieto González
(alu0101546377@ull.edu.es)

Introducción	3
Resultados procesamiento	3
Análisis de los resultados de la tabla	4
Resultados matriz de similitud entre cosenos	4

Introducción

Este informe documenta la práctica sobre sistemas de recomendación basados en el contenido. Se describe el objetivo y la metodología seguida (preprocesado, lematización, cálculo de TF, IDF y TF-IDF), la implementación del software, los resultados obtenidos (tablas por documento y matriz de similitud coseno) y las conclusiones. Se incluyen además 10 documentos propuestos para realizar pruebas adicionales y las instrucciones para ejecutar el software y reproducir los resultados.

Resultados procesamiento

El programa se ejecuta desde la línea de comandos y permite analizar cualquier conjunto de documentos que el usuario desee. A través de la consola, se muestran los resultados del procesamiento, incluyendo los valores de TF-IDF y la similitud coseno entre los textos seleccionados.

De los análisis de la ejecución podemos sacar las siguientes conclusiones en cuanto al procesamiento:

En cuanto a la calidad del procesado, con los documentos originales se eliminaron aproximadamente la mitad de los elementos y se mapearon más de 1000 palabras:

```
Original words: 8836  
After removing stop words: 4236  
Lemmatized words: 1013
```

En cuanto a los nuevos documentos tenemos los siguientes resultados:

```
Original words: 1014  
After removing stop words: 710  
Lemmatized words: 46
```

Y en el caso del Quijote:

```
Original words: 201148  
After removing stop words: 155122  
Lemmatized words: 8753
```

Este alto porcentaje de lematización correcta reduce el vocabulario y mejora la similitud cuando la misma idea aparece con flexiones distintas.

Análisis de los resultados de la tabla

En cuanto a los resultados de la tabla, vamos a utilizar como ejemplo los resultados de ejecutar los documentos 1 y 2 originales.

En el primer documento, palabras como *water*, *stillness*, *notebook*, *notice* y *moment* obtuvieron los valores más altos de TF-IDF, destacando temas relacionados con la reflexión, la observación y la tranquilidad.

En el segundo documento, los términos más relevantes fueron *notebook*, *quiet*, *rhythm*, *stretch*, *day*, *life*, *path*, *lake*, *water*, *feel* y *walk*. Estos resultados reflejan motivos recurrentes de contemplación, movimiento y conexión con la naturaleza, en coherencia con el tono del primer texto.

La similitud coseno de **0.679** entre ambos documentos indica una semejanza semántica moderada a alta, lo que sugiere que comparten vocabulario y enfoque conceptual similares. Esto refuerza la capacidad del modelo para capturar coherencia temática e identificar relaciones entre textos con elementos descriptivos y reflexivos comunes.

En conjunto, el modelo logró extraer características lingüísticas distintivas y cuantificar la similitud entre documentos, demostrando su fiabilidad para tareas como la agrupación temática y la recomendación basada en contenido textual.

Resultados matriz de similitud entre cosenos

En cuanto a la matriz de similitud de coseno, en los nuevos documentos, entre el 01 y el 09 podemos sacar el siguiente análisis:

- Los valores de similitud coseno están todos entre 0.15 y 0.25.
- Ningún documento es muy diferente, pero tampoco hay una coincidencia temática completa.
- Los principales términos comunes son “*viaje*”, “*tren*”, “*día*”, “*vida*”.
- Los documentos 04, 05 y 06 son los más parecidos al document-01.

En el caso de los antiguos documentos, entre el 01 y el 09, la similaridad está entre 0.65 y 0.75, lo que indica que los documentos del conjunto original presentan un alto grado de relación semántica entre sí.

Se observa que los pares de documentos con mayor similitud coseno son:

- document-05.txt ↔ document-06.txt (0.75)
- document-07.txt ↔ document-09.txt (0.7493)

- document-06.txt ↔ document-09.txt (0.7305)

Estos resultados reflejan una fuerte correlación semántica, lo que implica que dichos textos tratan temas muy próximos y comparten una estructura conceptual similar.

Por el contrario, los pares con menor similitud (en torno a 0.65) corresponden a combinaciones como:

- document-01.txt ↔ document-08.txt (0.6561)
- document-02.txt ↔ document-04.txt (0.6606)

Esto indica que, aunque siguen perteneciendo al mismo dominio, presentan un léxico menos coincidente o un enfoque más diferenciado dentro del mismo campo temático.